Algoritmos e Estruturas de Dados II **Prof. Ricardo J. G. B. Campello**



Árvores B – Parte I

Introdução

Adaptado e Estendido dos Originais de:

Leandro C. Cintra Maria Cristina F. de Oliveira



A Invenção da B-Tree

- Bayer and McGreight, 1972, publicaram o artigo: "Organization and Maintenance of Large Ordered Indexes"
- Em 1979, o uso de árvores-B para manutenção de índices de bases de dados já era praticamente padrão em sistemas de arquivos de propósito geral



Problema

- Acesso a disco é custoso (lento)
- Se o índice é grande e não cabe em memória principal, busca binária exige muitos acessos
 - 15 itens podem requerer log₂(15) ≅ 4 acessos
 - 1.000 itens podem requerer $log_2(1000) \cong 10$ acessos
 - São números muito altos para relativamente poucos itens

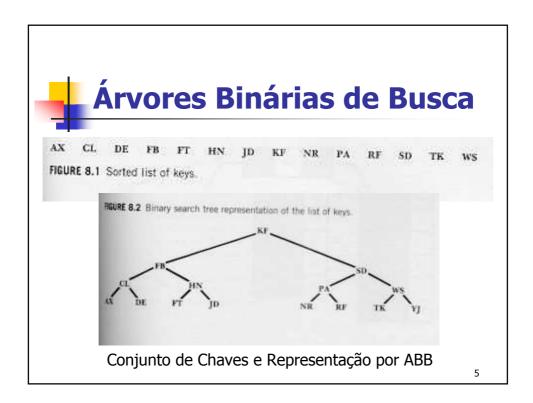
3

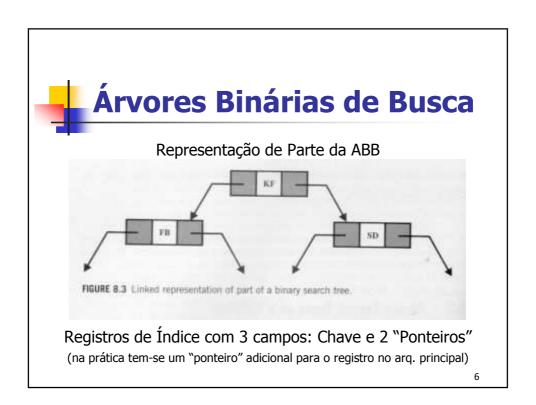


Problema

- Um problema ainda mais crítico é o custo de manter o índice ordenado em disco
 - BB demanda reorganização de índices dinâmicos
 - Inserção ou remoção de item pode afetar todo o índice
- É necessária uma ED na qual a inserção e a remoção de registros tenha apenas efeitos locais
 - ED que não exija a reorganização total do índice
- Solução ?

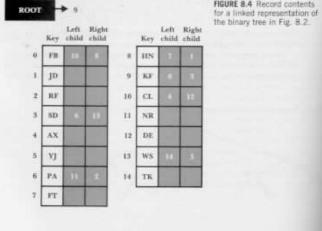
4







Árvores Binárias de Busca



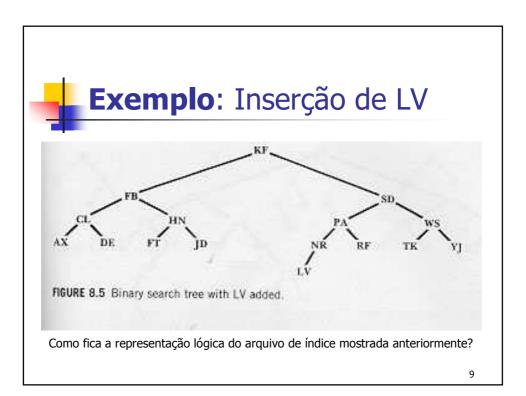
Representação lógica do arquivo índice

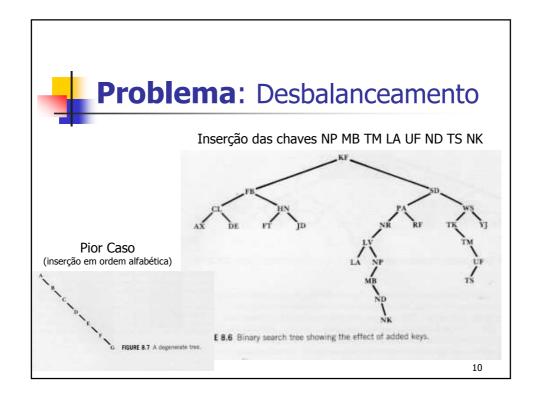
7

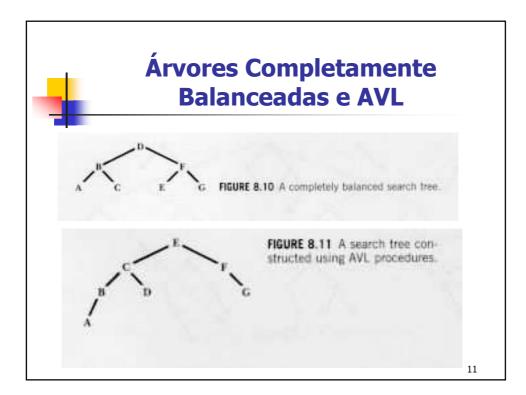


ABBs: Vantagens

- Ordem lógica da ED não está associada à ordem lógica ou física dos registros no arquivo de índice
- Índice não precisa mais ser mantido ordenado:
 - O que interessa é recuperar a estrutura lógica da árvore, o que é possível com os "ponteiros" RRN
- Inserção de uma nova chave no arquivo
 - É necessário saber onde inserir esta chave na árvore
 - Busca é necessária, mas reorganização do arquivo não é









Árvores Completamente Balanceadas e AVL

- A eficiência de ABBs exige mantê-las balanceadas
- Árvores completamente balanceadas:
 - Busca demanda $\approx \log_2(N+1)$ comparações de chaves no pior caso
 - Corresponde à altura da árvore
 - Para N = 1.000.000 chaves, busca percorre até **20 níveis**
 - Mas só é viável computacionalmente se árvore for estática
- No caso dinâmico, balanceamento requer árvores AVL
 - Busca demanda ≈ 1.44*log₂(N+2) comparações no pior caso
 - Para N = 1.000.000 chaves, busca percorre até 28 níveis



Árvores Completamente Balanceadas e AVL

- Entretanto, se as chaves estão em memória secundária, qualquer procedimento que exija mais do que 5 ou 6 acessos para localizar uma chave é altamente indesejável
 - 20 ou 28 acessos são inaceitáveis
- Em resumo, no caso de índices dinâmicos:
 - AVLs resolvem apenas um dos dois principais problemas dos índices lineares ordenados:
 - nunca requerem a re-organização global do índice em uma modificação
 - no entanto, reduzem mas n\u00e3o resolvem o no. excessivo de acessos requerido em uma busca e, portanto, em qualquer outra opera\u00e7\u00e3o

13



- A busca (seek) por uma posição específica do disco é lenta
- Mas uma vez encontrada a posição, pode-se ler uma grande quantidade registros seqüencialmente a um custo relativamente baixo
- Esta combinação de busca (seek) lenta e transferência rápida sugere a noção de página

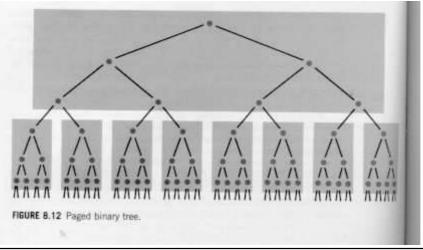


Página:

- Um conjunto de registros fisicamente contíguos passíveis de serem recuperados em um único acesso
 - p. ex. registros ocupando um setor ou cluster
 - se o próximo registro a ser recuperado estiver na mesma página do anterior, evita-se um novo acesso ao disco
- Pode conter um número grande de registros
- Refere-se aos arquivos organizados em páginas como arquivos paginados (paged files)

15







- Na ABB da figura anterior:
 - qq. dos 63 itens é recuperado em, no máximo, 2 acessos!
- Com um nível adicional:
 - ter-se-ão 64 novas páginas
 - o que representa 64 x 7 = 448 itens adicionais
 - qq. dos 511 itens é recuperado em, no máximo, **3 acessos**!
- Com outro nível adicional:
 - qualquer dos 4095 itens pode ser recuperado em no máx. 4 acessos!
 - busca binária de 4095 itens pode demandar até 12 acessos

17



- Outro Exemplo:
 - páginas com 511 itens
 - cada página contém uma árvore completamente balanceada
 - 1+2+4+8+16+32+64+128+256=511 itens
 - OBS: $511 = 2^8 1 = 2^0 + 2^1 + \dots + 2^7$
- ABB com 3 níveis pode armazenar 134.217.727 itens
 - \bullet 511 + 512*511 + 512²*511 = 134.217.727
 - qq. item é recuperado em, no máximo, 3 acessos !!!



- Desempenho de Pior caso:
 - ABB completamente balanceada: log₂ (N+1) acessos
 - Versão paginada: log_{k+1} (N+1) acessos
 - k = no. de itens em uma página (k=1 para a versão não paginada)
 - N = no. de itens
 - Exemplo anterior:
 - ABB (k=1): log₂ (134.217.727) = **27 acessos**
 - Versão paginada (k = 511): log₅₁₁₊₁ (134.217.727) = 3 acessos

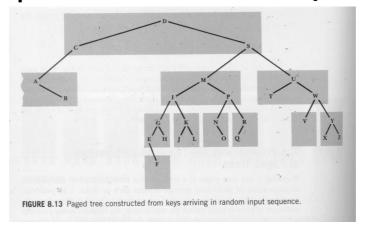
19



- É simples construir uma árvore paginada se todo o conjunto de chaves é conhecido antes de iniciar a construção
 - Toma-se a chave mediana para obter uma divisão balanceada, de forma recursiva
- Porém, é complicado se as chaves são recebidas em uma seqüência aleatória



■ Exemplo: CSDTAMPIBWNGURKEHOLJYQZFXV



21



Árvores Binárias Paginadas

- No exemplo anterior:
 - Construção top-down, a partir da raiz
 - Sempre que uma chave é inserida, a árvore dentro da página é reajustada para manter o balanceamento interno

Problema:

- Chaves pequenas no topo, como C e D, podem acabar desbalanceando a árvore de forma definitiva
 - A árvore do exemplo não está tão ruim, mas o que aconteceria se as chaves fossem fornecidas em ordem alfabética?

22



Problema:

- É necessário manter o balanceamento após inserções e remoções
 - com a restrição dos itens estarem agrupados em páginas...
- Questões :
 - como garantir que as páginas formem uma árvore balanceada ?
 - p. ex., como impedir o agrupamento de chaves como C, D e S no exemplo anterior ?
 - como garantir que cada página contenha um no. mínimo de chaves ?

23



- Em resumo, como garantir:
 - que as páginas formem uma árvore balanceada?
 - que cada página contenha um no. mínimo de chaves ?
- Rotações AVL não satisfazem as necessidades acima
 - não se pode rotar páginas inteiras como se fossem itens individuais
 - páginas contêm múltiplas chaves e múltiplos descendentes
 - rotações tradicionais implicariam a modificação de várias páginas
 - não possuem apenas efeitos locais
- Solução: Árvores B!



Exercícios

- Ilustre graficamente uma ABB completamente balanceada com 15 chaves numéricas inteiras agrupadas em páginas de k=3 chaves internamente também balanceadas.
- 2. Repita o exercício anterior assumindo que as chaves são inseridas de forma aleatória.
- 3. Estime a quantidade de acessos no pior caso de busca por um item em um arquivo com 16.777.215 itens organizado como uma ABB completamente balanceada não paginada
- 4. Repita o exercício 3 para uma ABB do tipo AVL.
- 5. Repita o exercício 3 assumindo uma paginação de k=63

25



Bibliografia

 M. J. Folk and B. Zoellick, File Structures: A Conceptual Toolkit, Addison Wesley, 1987.