### Sumário

- Introdução:
- Etapas para o desenvolvimento e análise de Programas Paralelos;
- Computação Paralela sobre Sistemas Distribuídos;
- Ambientes para Troca de Mensagens;
  - PVM;
  - MPI;
- Resultados;

### Sumário

- Referências para consulta:Onde encontrar mais informações...
- ALMASI, G., GOTTLIEB, A., Highly Parallel Computing, Second Edition, The Benjamin/Cummings Publishing Company, 1994.
- QUINN, M. J., *Parallel Computing: Theory and Practice*, Second Edition, McGRAW-HILL, 1994.
  - Sunderam, V. S., Geist, G. A., Dongarra, J. and Manchek, R., *The PVM Concurrent Computing System: Evolution, Experiences, and Trends*, Parallel Computing, Vol. 20, No. 4, pp.531-545, April 1994.

McBryan, O. A., *An Overview of Message Passing Environments*, Parallel Computing, vol. 20, pp. 417-444, 1994.

### Sumário

- Referências para consulta:Onde encontrar mais informações...
- Na Internet:
  - http://www.epm.ornl.gov/pvm/pvm\_home.html
  - http://www.mpi-forum.org
  - http://www.lam-mpi.org
  - http://lasdpc.icmc.sc.usp.br

- Busca por melhor desempenho e menor custo;
- Máquinas "von Neumann"
  - Programação Seqüencial → Uma tarefa por vez;
  - Gargalo de von Neumann → Baixo desempenho;
  - Serialização de problemas paralelos.
- Solução: Arquiteturas Paralelas
  - Programação paralela;
  - Vários processadores trabalhando em uma mesma tarefa;
  - Diversas instruções são executadas em paralelo.

Definição de Programação Paralela

Vários Processos Executados em diferentes Processadores e Trabalhando em Conjunto em um Único Problema

Coleção de Elementos de Processamento que se comunicam e cooperam entre si e resolvem um Problema mais Rapidamente (Almasi)

Processamento de Informação que enfatiza a manipulação Concorrente de Dados que Pertencem a um ou mais Processos que Resolvem um único Problema

- Histórico:
  - 1953: bits  $\rightarrow$  palayras;
  - 1958: Processadores de E/S;
  - Anos 70: Pipelines e Processadores de Ponto Flutuante
    - 1975 Illiac IV:
      - Paralelismo de alto nível;
      - 64 processadores;
      - 16 racks;
      - Área de uma quadra de basquete!

- Histórico:
  - Anos 80:
    - Computadores Vetoriais → Cray;
    - Máquinas SIMD (Single Instruction Multiple Data);
    - Máquinas MIMD (Multiple Instruction Multiple Data);
    - Dataflow.
  - Problema: Custo

- Solução: VLSI (anos 80)
  - Popularização dos computadores pessoais;
  - Máquinas com vários processadores;
  - Arquiteturas paralelas a um custo acessível.

- Histórico:
  - Final dos anos 80:
    - Possibilidade de utilizar o hardware dos Sistemas Distribuídos como uma arquitetura paralela de memória distribuída (MIMD);
    - Convergência entre as áreas de Computação Paralela e Sistemas Distribuídos;

- É importante diferenciar os termos:
  - Programação Sequencial;
  - Programação Concorrente;
  - Programação Paralela;

- Programação Seqüencial:
  - Várias tarefas sendo executadas uma após a outra.
- Programação Concorrente:
  - Várias tarefas sendo executadas concorrentemente;
  - Em arquiteturas paralelas (vários processadores) têm-se: Programação Paralela;
  - Único processador: Pseudo-Paralelismo;
  - Programação Paralela:
    - Vários processos executados em diferentes processadores trabalhando em conjunto em um único problema;

- **Exemplos:** 
  - Como Preparar uma Refeição;
  - Multiplicação paralela de matrizes;

Programação Seqüencial - Multiplicação de matrizes: Inicializar Matrizes A[i][k] e B[k][j];

ler toda a matriz A
ler toda a matriz B
ler toda a matriz B
Para t de 1 até i faça
Para y de 1 até j faça
Para x de 1 até k faça
Matriz C[t][y] += A[t][x]\*B[x][y]

As matrizes devem ser inteiramente lidas e depois é realizada a multiplicação

Programação Concorrente - Multiplicação de matrizes:

Inicializar Matrizes A[i][k] e B[k][j]; Para t de 1 até i faça - Proc PAt ler linha t da matriz A Para y de 1 até j faça - Proc PBy ler coluna y da matriz B Para t de 1 até i faça - Proc Pcy Para y de 1 até j faça Para x de 1 até k faça Matriz C[t][y] += A[t][x]\*B[x][y]


Leitura e multiplicação realizadas de maneira concorrente

- Programação Concorrente:
  - Com o exposto, pode ser verificado que:






- Programação Concorrente:
  - Considerando 3 estados para um processo em um processador;




- E que:
  - Processo PAt: Lê linha t da matriz A
  - Processo PBy: Lê coluna y da matriz B
  - Processo PCy: Multiplica a linha t da matriz A pela coluna y da matriz B


- Programação Concorrente:
  - Tem-se que:



- Programação Concorrente:
  - Tem-se que:




Programação Concorrente:
Tem-se que:




- Programação Concorrente:
  - Tem-se que:



- Programação Concorrente:
  - Tem-se que:



- Programação Concorrente:
  - Nota-se que nesse estágio existem tarefas sendo executadas concorrentemente!



### Programação Paralela - Multiplicação de matrizes:

#### Processador 1

**Processador 2** 


**Processador 3** 

Inicializar Matrizes A[i][k] e B[k][j]; ler matriz A; enviar matriz A receber matriz B para i de 1 até (k/3) calcular parte da matriz C


ler matriz B
receber matriz A
enviar matriz B
para i de k/3+1 até 2\*(k/3)
calcular parte da matriz
C

receber matriz A
receber matriz B
para i de 2\*(k/3)+1 até k
calcular parte da matriz C


#### **Processador 1**



#### **Processador 2**



#### **Processador 3**



Qual o número ideal de processadores para realizar uma tarefa?

- Qual deve ser a potência e a função de cada um?
- Questões que devem ser verificadas:
  - Sincronismo entre os processos;
  - Granulação das tarefas;
  - Balanceamento de carga;
  - Organização da memória:
    - Centralizada;
    - Distribuída
  - Desempenho.

- Comunicação e Sincronismo:
  - Como um processador informa aos outros sobre uma multiplicação que deve ser realizada?
  - Como receber os resultados de todos os processadores que ajudaram no processamento?
  - Como é efetuada a comunicação e o sincronismo entre processos/processadores?

- Comunicação e Sincronismo:
  - Utilização de Redes de Interconexão:
    - Relação Custo x Desempenho;
    - Conectividade;
    - Velocidade;
    - Custo;
    - Caminhos Alternativos;
      - Exemplos: Redes Crossbar, Ethernet, Linear, Estrela, etc.
  - Com relação ao sincronismo...
    - Algoritmo Sequencial: Ordenação Total;
    - Algoritmo Paralelo: Ordenação Parcial → Não Determinismo.

- Granulação das tarefas: Tamanho das unidades de trabalho submetidas aos processadores;
  - Fatores que influenciam:
    - Número de Processos/Processadores considerados;
    - Tamanho de cada tarefa.
  - Classificada em Fina, Média e Grossa;

- Granulação das tarefas:
  - Granulação fina: Paralelismo de baixo nível
    - Grande número de processos pequenos e simples;
    - Unidade de paralelismo: instruções/operações;
  - Granulação Média: Paralelismo de nível médio
    - Vários processos;
    - Unidade de paralelismo: Procedimentos/funções/loops.
  - Granulação Grossa: Paralelismo de alto nível
    - Poucos processos grandes e complexos;
    - Unidade de paralelismo: Processos/Programas;

- Balanceamento de carga:
  - Como dividir as tarefas entre os processadores?
  - É desejável atribuir uma tarefa "adequada" para cada processador;
  - Tentativa de minimizar comunicação e sincronismo.

- Organização da memória:
  - Como a memória é organizada?
  - Qual a quantidade de memória necessária?
  - Fatores que podem influenciar na organização da memória:
    - Potência dos Processadores;
    - Relação Processamento/Comunicação;
    - Freqüência e tipo de E/S.

- Organização da memória:
  - Pode ser:
    - Compartilhada: Espaço de endereçamento único entre todos os processadores;
    - Distribuída: Espaço de endereçamento individual (para cada processador).

### Desempenho:

- Há vantagem na utilização de mais que um processador?
- Quantos processadores seriam necessários?
- Como medir a vantagem na utilização da computação paralela?
- Pode-se fazer uso de duas medidas:
  - Speedup: Qual o ganho na utilização da computação paralela?
  - Eficiência: Quanto da potência computacional envolvida foi utilizada?

### Desempenho:

Speedup (Sp): Relação entre o tempo para executar um algoritmo em um único processador ( $T_1$ ) e o tempo para executá-lo em p processadores ( $T_2$ );

$$Sp=T_1/T_p$$

### Exemplo:

- Tempo para execução da multiplicação de matrizes em um processador: T1=10 ut
- Tempo para execução da multiplicação de matrizes em 3 processadores: Tp=4 ut (p=3)
- Speedup alcançado  $\rightarrow$  Sp = 10/4  $\rightarrow$  Sp = 2,5

- Desempenho:
  - Eficiência (Ef): Relaciona *Speedup* e o número de processadores;

- Tomando como base o exemplo anterior (Sp=2,5 e p=3);
  - Efficiência  $\rightarrow$  Ef=2,5/3  $\rightarrow$  Ef = 0,83
- No caso ideal:
  - Speedup=p e Eficiência = 1
- No caso real:
  - Speedup

- Vantagens
- Alto Desempenho fim do Gargalo de von Neumann;
- Solução mais Natural para Problemas Intrinsecamente Paralelos;
- Maior Facilidade de implementação de Tolerância a Falhas;
- Desenvolvimento de Programas Modulares.

- Desvantagens
- Programação mais Complexa;
- Sobrecargas Introduzidas na Comunicação e Sincronismo.

### Tarefa para casa

Ler o Capítulo 1 do Livro:

ALMASI, G., GOTTLIEB, A., *Highly Parallel Computing*, Second Edition, The Benjamin/Cummings Publishing Company, 1994.