

PERCEPTRON


- Características Básicas
- Modelo de Neurônio
- Estrutura da Rede
- Algoritmo de Aprendizado

CARACTERÍSTICAS BÁSICAS

- Regra de propagação $net_j = \sum_i x_i w_{ij} + \theta_i$
- Função de ativação: Degrau
- Topologia: uma única camada de processadores
- Algoritmo de Aprendizado: $\Delta w_{ij} = \eta x_i(t_j - s_j)$ (supervisionado)
- Valor de Entrada/Saída: Binários

MODELO DO NEURÔNIO


Na sua forma mais simples, o modelo do processador consiste em:



$$s_j = F(net_j) = F\left(\sum_i x_i w_{ij} + \theta_i\right) = \begin{cases} 1 & net_j > 0 \\ 0 & net_j \leq 0 \end{cases}$$

PERCEPTRON

Finalidade do Termo Bias:



$$\sum_i x_i w_{ij} = 0 \quad \text{Define um hiperplano passando pela origem}$$

$$\sum_i x_i w_{ij} + \theta_i = 0 \quad \text{Desloca-se o hiperplano da origem}$$

ALGORITMO DE APRENDIZADO

- 1) iniciar os pesos sinápticos com valores randomicos e pequenos ou iguais a zero;
- 2) aplicar um padrão com seu respectivo valor desejado de saída (t_j) e verificar a saída da rede (s_j);
- 3) calcula o erro na saída $E_j = t_j - s_j$;
- 4) se $E_j = 0$, volta ao passo 2;
se $E_j \neq 0$, atualiza os pesos: $\Delta w_{ij} = \eta x_i E_j$;
- 5) volta ao passo 2.

ALGORITMO DE APRENDIZADO

IMPORTANTE

- não ocorre variação no peso se a saída estiver correta;
- caso contrário, cada peso é incrementado de η quando a saída é menor que o alvo (valor desejado) e decrementado de η quando a saída é maior que o alvo.


$$\Delta w_{ij} = \eta x_i e_j$$

PERCEPTRON

Relembra um pouco conhecimento de Cálculo

Gradiente: $\nabla f(x, y) = \left(\frac{\partial}{\partial x} f(x, y), \frac{\partial}{\partial y} f(x, y) \right)$

Derivada direcional: $D_{\mathbf{u}} f(x, y) = \nabla f(x, y) \cdot \mathbf{u}$
 $= \|\nabla f(x, y)\| \|\mathbf{u}\| \cos \gamma$
 $= \|\nabla f(x, y)\| \cos \gamma$



$D_{\mathbf{u}} f(x, y)$ é a taxa de variação de $f(x, y)$ na direção definida por \mathbf{u} .

PERCEPTRON

Relembra um pouco conhecimento de Cálculo (cont.)

Teorema do gradiente: Seja f uma função de duas variáveis, diferenciáveis no ponto $P(x, y)$.


- i) O máximo de $D_{\mathbf{u}} f(x, y)$ em $P(x, y)$ é $\|\nabla f(x, y)\|$.
- ii) O máximo da taxa de crescimento de $f(x, y)$ em $P(x, y)$ ocorre na direção de $\nabla f(x, y)$.

Corolário: Seja f uma função de duas variáveis, diferenciáveis no ponto $P(x, y)$.


- i) O mínimo de $D_{\mathbf{u}} f(x, y)$ em $P(x, y)$ é $-\|\nabla f(x, y)\|$.
- ii) O máximo da taxa de decréscimo de $f(x, y)$ em $P(x, y)$ ocorre na direção de $-\nabla f(x, y)$.

PERCEPTRON

Superfície de Erro



Processo de Minimização



A direção do gradiente negativo é a de descida mais íngreme ("steepest descent")

PERCEPTRON

Método do Gradiente Descendente (GD)

$$\Delta w_{ij} = -\eta \frac{\delta E_j}{\delta w_{ij}}$$

Cada *peso sináptico i* do elemento processador *j* é atualizado proporcionalmente ao *negativo da derivada parcial do erro* deste processador com relação ao peso.

PERCEPTRON

Logo:

$$\Delta w_{ij} = -\eta \frac{\delta E_j}{\delta w_{ij}} = -\eta \frac{\delta E_j}{\delta s_j} \frac{\delta s_j}{\delta w_{ij}}$$

$$E_j = \frac{1}{2} (t_j - s_j)^2 \quad s_j = k \sum x_i \cdot w_{ij} + \theta$$

$$\Delta w_{ij} = -\eta \cdot \left[2 \cdot \frac{1}{2} (t_j - s_j) \cdot (-1) \right] \cdot x_i$$


$$= -\eta \cdot [-(t_j - s_j)] \cdot x_i = \eta x_i (t_j - s_j)$$

EXEMPLO

Simulação do Operador Lógico AND

AND	x_0	x_1	x_2	t
Entrada 1:	1	0	0	0
Entrada 2:	1	0	1	0
Entrada 3:	1	1	0	0
Entrada 4:	1	1	1	1

Peso inicial: $w_0 = 0, w_1 = 0, w_2 = 0$
 Taxa de aprendizado: $\eta = 0.5$



EXEMPLO

1ª Cicle

Entrada 1: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 0 \times 0 + 0 \times 0) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 2: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 0 \times 1 + 0 \times 0) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 3: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 0 \times 0 + 0 \times 1) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 4: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 0 \times 1 + 0 \times 1) = f(0) = 0 \longrightarrow s_{\text{out}} \neq t$
 $w_0 = w_0 + (t - s_{\text{out}})x_0 = 0 + 0.5 \times (1 - 0) \times 1 = 0.5$
 $w_1 = w_1 + (t - s_{\text{out}})x_1 = 0 + 0.5 \times (1 - 0) \times 1 = 0.5$
 $w_2 = w_2 + (t - s_{\text{out}})x_2 = 0 + 0.5 \times (1 - 0) \times 1 = 0.5$

EXEMPLO

2ª Cicle

Entrada 1: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0.5 \times 1 + 0.5 \times 0 + 0.5 \times 0) = f(0.5) = 1 \longrightarrow s_{\text{out}} \neq t$

$$w_0 = w_0 + (t - s_{\text{out}})x_0 = 0.5 + 0.5 \times (0 - 1) \times 1 = 0$$

$$w_1 = w_1 + (t - s_{\text{out}})x_1 = 0.5 + 0.5 \times (0 - 1) \times 0 = 0.5$$

$$w_2 = w_2 + (t - s_{\text{out}})x_2 = 0.5 + 0.5 \times (0 - 1) \times 0 = 0.5$$

Entrada 2: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 0.5 \times 0 + 0.5 \times 1) = f(0.5) = 1 \longrightarrow s_{\text{out}} \neq t$

$$w_0 = w_0 + (t - s_{\text{out}})x_0 = 0 + 0.5 \times (0 - 1) \times 1 = -0.5$$

$$w_1 = w_1 + (t - s_{\text{out}})x_1 = 0.5 + 0.5 \times (0 - 1) \times 0 = 0.5$$

$$w_2 = w_2 + (t - s_{\text{out}})x_2 = 0.5 + 0.5 \times (0 - 1) \times 1 = 0$$

EXEMPLO

2ª Cicle

Entrada 3: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-0.5 \times 1 + 0.5 \times 1 + 0 \times 0) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 4: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-0.5 \times 1 + 0.5 \times 1 + 0 \times 1) = f(0) = 0 \longrightarrow s_{\text{out}} \neq t$
 $w_0 = w_0 + (t - s_{\text{out}})x_0 = -0.5 + 0.5 \times (1 - 0) \times 1 = 0$
 $w_1 = w_1 + (t - s_{\text{out}})x_1 = 0.5 + 0.5 \times (1 - 0) \times 1 = 1$
 $w_2 = w_2 + (t - s_{\text{out}})x_2 = 0 + 0.5 \times (1 - 0) \times 1 = 0.5$

EXEMPLO

3ª Cicle

Entrada 1: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 1 \times 0 + 0.5 \times 0) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 2: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(0 \times 1 + 1 \times 0 + 0.5 \times 1) = f(0.5) = 1 \longrightarrow s_{\text{out}} \neq t$

$$w_0 = w_0 + (t - s_{\text{out}})x_0 = -0.5 + 0.5 \times (0 - 1) \times 1 = -1$$

$$w_1 = w_1 + (t - s_{\text{out}})x_1 = 1 + 0.5 \times (0 - 1) \times 0 = 1$$

$$w_2 = w_2 + (t - s_{\text{out}})x_2 = 0.5 + 0.5 \times (0 - 1) \times 1 = 0$$

EXEMPLO

3ª Cicle

Entrada 3: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 1 + 0 \times 0) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 4: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 1 + 0 \times 1) = f(0) = 0 \longrightarrow s_{\text{out}} \neq t$
 $w_0 = w_0 + (t - s_{\text{out}})x_0 = -1 + 0.5 \times (1 - 0) \times 1 = -0.5$
 $w_1 = w_1 + (t - s_{\text{out}})x_1 = 1 + 0.5 \times (1 - 0) \times 1 = 1.5$
 $w_2 = w_2 + (t - s_{\text{out}})x_2 = 0 + 0.5 \times (1 - 0) \times 1 = 0.5$

EXEMPLO

4ª Cicle

Entrada 1: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-0.5 \times 1 + 1.5 \times 0 + 0.5 \times 0) = f(-0.5) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 2: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-0.5 \times 1 + 1.5 \times 0 + 0.5 \times 1) = f(0) = 0 \longrightarrow s_{\text{out}} = t$

Entrada 3: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-0.5 \times 1 + 1.5 \times 1 + 0.5 \times 0) = f(1) = 1 \longrightarrow s_{\text{out}} \neq t$

$$w_0 = w_0 + (t - s_{\text{out}})x_0 = -0.5 + 0.5 \times (0 - 1) \times 1 = -1$$

$$w_1 = w_1 + (t - s_{\text{out}})x_1 = 1.5 + 0.5 \times (0 - 1) \times 1 = 1$$

$$w_2 = w_2 + (t - s_{\text{out}})x_2 = 0.5 + 0.5 \times (0 - 1) \times 0 = 0.5$$

Entrada 4: $s_{\text{out}} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 1 + 0.5 \times 1) = f(0.5) = 1 \longrightarrow s_{\text{out}} = t$

EXEMPLO

5ª Ciclo

Entrada 1: $s_{out} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 0 + 0.5 \times 0) = f(-1) = 0 \rightarrow s_{out} = f$


Entrada 2: $s_{out} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 0 + 0.5 \times 1) = f(-0.5) = 0 \rightarrow s_{out} = f$

Entrada 3: $s_{out} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 1 + 0.5 \times 0) = f(0) = 0 \rightarrow s_{out} = f$


Entrada 4: $s_{out} = f(w_0x_0 + w_1x_1 + w_2x_2)$
 $= f(-1 \times 1 + 1 \times 1 + 0.5 \times 1) = f(0.5) = 1 \rightarrow s_{out} = t$

$$w_0 = -1, w_1 = 1, w_2 = 0.5$$

INTERPRETAÇÃO GEOMÉTRICA



O PROBLEMA DO OU-EXCLUSIVO (XOR)



Exercicio

- Treinar um perceptron para implementar a função lógica OR.


O PROBLEMA DO OU-EXCLUSIVO (XOR)

Conclusão

- mudando-se os valores de w_1 , w_2 e θ , muda-se a inclinação e a posição da reta;
- entretanto é impossível achar uma reta que divide o plano de forma separar os pontos A_1 e A_2 de um lado e A_0 e A_3 de outro
- redes de 1 única camada só representam

funções linearmente separáveis

O PROBLEMA DO OU-EXCLUSIVO (XOR)




O PROBLEMA DO OU-EXCLUSIVO (XOR)

Minsky & Papert provaram que este problema pode ser solucionado adicionando-se uma outra camada intermediária de processadores- Multi-Layer Perceptron (MLP)

O PROBLEMA DO OU-EXCLUSIVO (XOR)

Exemplo:




O PROBLEMA DO OU-EXCLUSIVO (XOR)

Exemplo do OU-EXCLUSIVO:

- J = 2 (número de entradas originais - x_1, x_2)
- H = 1 (número de entradas adicionais - $x_1 \cdot x_2$)

Pontos	Entradas	Saída
A	-1 -1	-1
B	-1 1	1
C	1 -1	1
D	1 1	-1

Problema Linearmente Separável



UMA OBSERVAÇÃO

- Redes Neurais de múltiplas camadas só oferecem vantagens sobre as de uma única camada se existir uma função de ativação não-linear entre as camadas.

Camada Escondida: $Net_1 = S_0 W_1$

$$S_1 = k_1 Net_1$$

Camada de Saída: $S_2 = k_2 Net_2 = k_2 (S_1 W_2)$

$$= k_2 ((k_1 Net_1) W_2)$$

$$= k_2 ((k_1 S_0 W_1) W_2)$$

$$= k_2 k_1 (S_0 W_1) W_2$$

$$= K S_0 (W_1 W_2)$$

$$= K S_0 W$$

Equivalente a uma única camada

MULTI-LAYER PERCEPTRON

- Redes de apenas uma camada só representam funções linearmente separáveis
- Redes de múltiplas camadas solucionam essa restrição
- O desenvolvimento do algoritmo Back-Propagation foi um dos motivos para o ressurgimento da área de redes neurais