


# Introdução às Redes Neurais

## Redes RBF: Parte III


Prof. Ricardo J. G. B. Campello

## Modelo RBF (revisão)



$$y = \sum_{i=1}^m w_i \cdot h_i(x_1, \dots, x_n) = \mathbf{h}^T \cdot \mathbf{w}$$

## Modelo RBF (revisão)



3

## Treinamento RBF (revisão)

### ◆ Problemas:

- Dadas as funções de base radial, como determinar o melhor vetor de pesos  $\mathbf{w}$  ?
- Como determinar bons parâmetros para as funções de base radial (centros e aberturas) ?
  - reduzir no. de funções para dada precisão, ou
  - aumentar precisão para dado no. de funções

4

## Treinamento RBF (revisão)

### ◆ Problemas:

- **Dadas as funções de base radial, como determinar o melhor vetor de pesos  $\mathbf{w}$  ?**
- Como determinar bons parâmetros para as funções de base radial (centros e aberturas) ?
  - reduzir no. de funções para dada precisão, ou
  - aumentar precisão para dado no. de funções

5

## Obtenção dos Pesos (revisão)

- ◆ Para  $k = 1, \dots, N$  padrões de entrada  $\mathbf{x}_k$  e saída  $y(\mathbf{x}_k)$ , deseja-se que a rede RBF possua pesos  $\mathbf{w}$  tais que:

$$\underbrace{\begin{bmatrix} 1 & h_1(\mathbf{x}_1) & \cdots & h_m(\mathbf{x}_1) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & h_1(\mathbf{x}_N) & \cdots & h_m(\mathbf{x}_N) \end{bmatrix}}_{\mathbf{H}} \cdot \underbrace{\begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_m \end{bmatrix}}_{\mathbf{w}} = \underbrace{\begin{bmatrix} y(\mathbf{x}_1) \\ \vdots \\ y(\mathbf{x}_N) \end{bmatrix}}_{\mathbf{y}}$$

o que implica:

$$\mathbf{w} = (\mathbf{H}^T \cdot \mathbf{H})^{-1} \cdot \mathbf{H}^T \cdot \mathbf{y}$$

6

## Treinamento RBF (revisão)

### ◆ Problemas:

- Dadas as funções de base radial, como determinar o melhor vetor de pesos  $\mathbf{w}$  ?
- **Como determinar bons parâmetros para as funções de base radial (centros e aberturas)?**
  - reduzir no. de funções para dada precisão, ou
  - aumentar precisão para dado no. de funções

7

## Determinação das Funções Radiais

### ◆ Método 1 (Heurística Simples):

- Distribuir as funções de maneira homogênea sobre o domínio das variáveis de entrada
- Por exemplo, se a rede possui duas entradas,  $x_1$  e  $x_2$ , que assumem valores no intervalo  $[-10, +10]$ , então o domínio das funções são todos os pontos  $(x_1, x_2)$  tais que  $x_1 \in [-10, +10]$  e  $x_2 \in [-10, +10]$

8

## Determinação das Funções Radiais

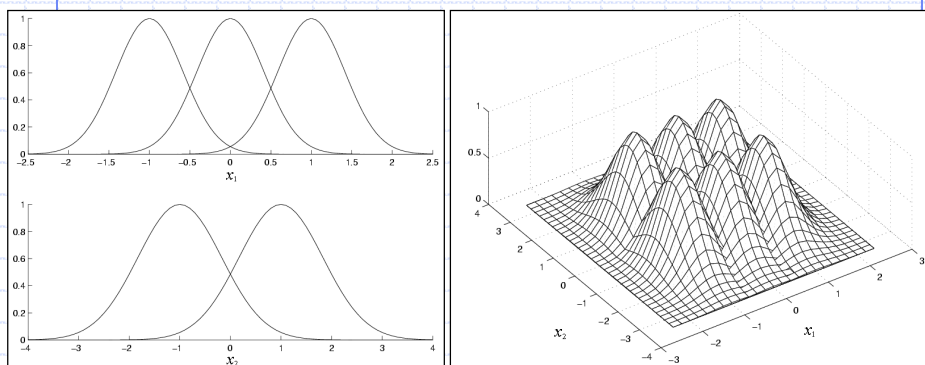
### ◆ Método 1 (cont.):

- Os centros das funções com relação a cada variável (dimensão) podem ser distribuídos uniformemente (eqüidistantes) ao longo do domínio daquela var.
- As aberturas das funções (desvios padrão) com relação a cada variável podem ser feitas iguais à distância entre dois centros consecutivos.

9

## Determinação das Funções Radiais

### ◆ Método 1 (exemplo):



10

## Determinação das Funções Radiais

### ◆ Método 2 (back-propagation):

- Análogo ao treinamento de MLPs
- A cada iteração ajusta-se o conjunto de parâmetros (centros e aberturas das funções) no sentido de minimizar o erro entre a saída da rede e a saída desejada para um conjunto de padrões
- Usualmente tenta-se minimizar: 
$$J = \frac{1}{N} \sum_{k=1}^N (y(\mathbf{x}_k) - y_{\text{RBF}}(\mathbf{x}_k))^2$$
- Demanda o cálculo do gradiente (derivadas) de J com relação aos parâmetros...
- **Usualmente aplica-se para refinar o resultado inicial obtido com o método 1 ou método 3 (visto depois)**

11

## Exemplo

### ◆ Problema:

- Aproximar a função  $f(x) = \sin(2x) / \exp(x/5)$
- ◆ N = 21 padrões de entrada e saída (k = 1, ..., 21):

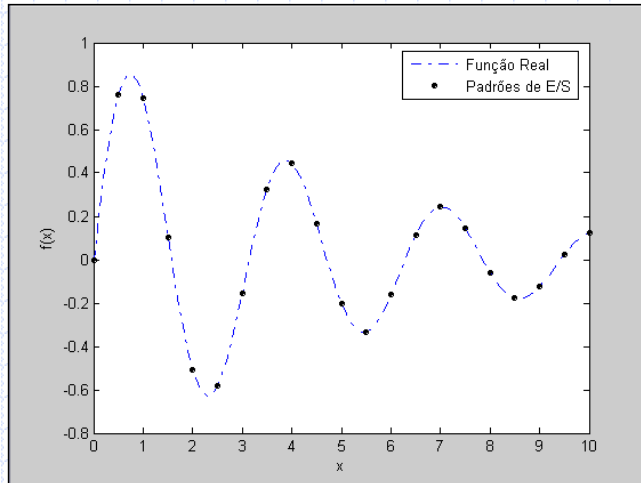
Padrão E/S	x	f(x)
1	0	0
2	0.5	0.7614
3	1.0	0.7445
4	1.5	0.1045
5	2.0	-0.5073
6	2.5	-0.5816
7	3.0	-0.1533
8	3.5	0.3262
9	4.0	0.4445
10	4.5	0.1676

11	5.0	-0.2001
12	5.5	-0.3329
13	6.0	-0.1616
14	6.5	0.1145
15	7.0	0.2443
16	7.5	0.1451
17	8.0	-0.0581
18	8.5	-0.1756
19	9.0	-0.1241
20	9.5	0.0224
21	10.0	0.1236

12

## Exemplo

◆ **Problema:** Aproximar a função  $f(x) = \sin(2x) / \exp(x/5)$



13

## Exemplo

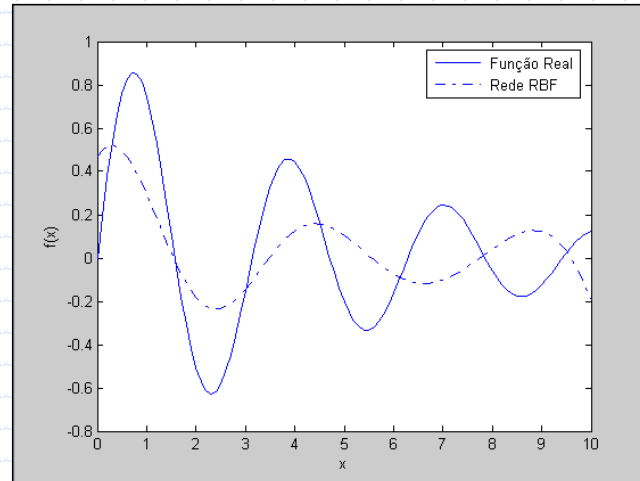
◆ **Solução 1 (Método 1):**

- Rede RBF com 6 neurônios (funções Gaussianas)
- Centros distribuídos de maneira uniforme
  - $c_1 = 0, c_2 = 2, c_3 = 4, c_4 = 6, c_5 = 8, c_6 = 10$
- Desvios padrão iguais à distância entre dois centros consecutivos
  - $\sigma_1 = \sigma_2 = \sigma_3 = \sigma_4 = \sigma_5 = \sigma_6 = 2$
- Apenas os pesos otimizados via Mínimos Quadrados (MQ):
  - 7 pesos ( $w_0 \dots w_6$ ) obtidos via MQ:  $\mathbf{w} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$

14

## Exemplo

### ◆ Resultado Solução 1:



15

## Exemplo

### ◆ Solução 2 (Método 1):


- Rede RBF com 11 neurônios
- Centros distribuídos de maneira uniforme
  - $c_1 = 0, c_2 = 1, c_3 = 2, \dots, c_{11} = 10$
- Desvios padrão iguais à distância entre dois centros consecutivos
  - $\sigma_1 = \sigma_2 = \dots = \sigma_{11} = 1$
- Apenas os pesos otimizados via Mínimos Quadrados (MQ):
  - 12 pesos ( $w_0 \dots w_{11}$ ) obtidos via MQ:  $\mathbf{w} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$

16



## Exemplo

### ◆ Resultado Solução 2:



17

## Exemplo


### ◆ Solução 3 (Método 1 + 2):

- Rede RBF com 6 neurônios
- Rede inicialmente configurada conforme Solução 1
- Sintonia fina realizada com **back-propagation**

18

## Exemplo

### ◆ Resultado Solução 3:



19

## Exemplo


### ◆ Solução 4 (Método 1 + 2):

- Rede RBF com 8 neurônios
- Rede inicialmente configurada de forma análoga à Solução 1
  - Porém com 8 neurônios (Gaussianas)
- Sintonia fina realizada com **back-propagation**

20

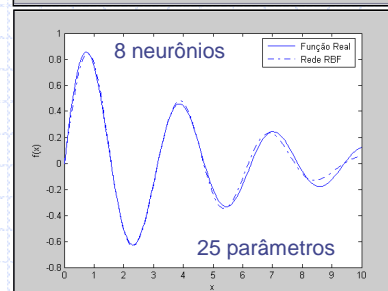



## Exemplo

### ◆ Resultado Solução 4:



21

## Exemplo (comparação)



2

## Exemplo (comparação)


### ◆ Notas:

- A heurística de distribuição homogênea das funções radiais (método 1) foi muito eficaz nesse exemplo agindo sozinha, mas não necessariamente é sempre assim
- Embora a rede com 8 neurônios refinados com back-propagation tenha uma quantidade de parâmetros maior durante a fase de **treinamento**, é um modelo mais simples e compacto do que aquele com 11 neurônios (para **utilização**).
- A rede com 11 neurônios poderia ficar ainda mais precisa se seus parâmetros também fossem refinados com back-propagation

23

## Dicas Básicas


- ◆ Usualmente utiliza-se apenas uma parcela dos padrões disponíveis para treinar a rede e reserva-se uma outra parcela para teste ou **validação**
- ◆ Uma boa heurística para saber quando interromper o treinamento (sintonia fina) dos parâmetros via back-propagation é observar os erros de ambas as parcelas:



24

## Dicas Básicas

- ◆ A mesma idéia pode ser usada para determinar quando parar de acrescentar neurônios à rede...



- ◆ Uma outra boa dica é normalizar os padrões de E/S de forma que cada variável tenha valores entre  $-1$  e  $+1$ 
  - Isso minimiza problemas numéricos durante o treinamento

25

## Determinação das Funções Radiais

### ◆ Método 3 (Clustering):


- Agrupar os padrões em grupos (clusters) de padrões mais similares entre si do que aos demais padrões.
- Associar um neurônio (função radial) para cada grupo de padrões, otimizando a representatividade de cada neurônio / função.
- Idéia é que cada neurônio responda de forma apropriada e similar a um determinado conjunto de padrões similares
  - Tipicamente (sub)classes em **problemas de classificação**

26

## Determinação das Funções Radiais

### ◆ Método 3 (cont.):

- Idéia intuitiva (1 var. de entrada):




27

## Determinação das Funções Radiais

### ◆ Método 3 (cont.):

- Idéia intuitiva (2 vars. de entrada):



28

## Determinação das Funções Radiais


### ◆ Método 3 (cont.):

- Um dos algoritmos de agrupamento mais populares é o **K-means**, que agrupa N padrões em K grupos:

- Escolher K protótipos iniciais dos grupos
  - padrões ou pontos quaisquer do domínio de entrada
- Atribuir cada um dos N padrões a um dos K grupos, de acordo com a maior proximidade aos protótipos dos grupos
- Recalcular os protótipos como **centróides** (ponto médio) dos padrões pertencentes àquele grupo
- Parar se não houver mais mudanças, ou retornar ao passo 2


29

### Exemplo de K-means: Iteração 1 / Passo 1




Fonte: Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus.

## K-means: Iteração 1 / Passo 2



Fonte: Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus.


## K-means: Iteração 1 / Passo 3



Fonte: Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus.




## K-means: Iteração 2 / Passo 2



Fonte: Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus.

## K-means: Iteração 2 / Passo 3 e Final



Fonte: Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus.

## Determinação das Funções Radiais


### ◆ Método 3 (cont.):

- Executa-se K-means com **K** igual ao número **m** de neurônios (funções radiais) desejado na rede RBF
- Toma-se o protótipo (centróide) de cada grupo resultante como centro de uma função radial
  - cada componente do centróide é o centro da função radial correspondente na respectiva variável
- Toma-se os desvios padrão de cada grupo, em cada variável, como o desvio padrão da função radial correspondente na respectiva variável
  - forma simplificada...

35

## Método 3 (Exemplo)

padrão (entrada)	$x_1$	$x_2$
1	1	2
2	2	1
3	1	1
4	2	2
5	8	9
6	9	8
7	9	9
8	8	8
9	1	15
10	2	15
11	1	14
12	2	14



Slide cedido pelo Prof. Eduardo Raul Hruschka

## Método 3 (Exemplo)

- ◆ K-means com  $K = 3$  produziria tipicamente os protótipos  $(1.5, 1.5)$ ,  $(8.5, 8.5)$ ,  $(1.5, 14.5)$
- ◆ O terceiro grupo, por exemplo, possui desvios padrão em  $x_1$  e em  $x_2$  respectivamente iguais a:

$$\sigma_1 = \sqrt{\frac{(1-1.5)^2 + (2-1.5)^2 + (1-1.5)^2 + (2-1.5)^2}{4}} = 0.5$$

$$\sigma_2 = \sqrt{\frac{(15-14.5)^2 + (15-1.5)^2 + (14-14.5)^2 + (14-14.5)^2}{4}} = 0.5$$

- ◆ Logo, a função radial (Gaussiana) correspondente pode ser definida como:

$$h_3(x_1, x_2) = \exp\left(-\frac{(x_1 - 1.5)^2}{0.5^2}\right) \times \exp\left(-\frac{(x_2 - 14.5)^2}{0.5^2}\right)$$

## Bibliografia

- ◆ Braga, et al., "Redes Neurais Artificiais: Teoria e Aplicações", LTC, 2ª Edição, 2007
- ◆ Haykin, "Neural Networks", Prentice Hall, 2<sup>nd</sup> Edition, 1999
- ◆ Kovács, "Redes Neurais Artificiais: Fundamentos e Aplicações", Collegium Cognitio, 2ª Edição, 1996