

EA072 – Projeto 1: Predição de Séries Temporais usando Redes Neurais Artificiais (MLP e RBF) Peso do Projeto: 5 || Data de entrega: 05/10/2006

1 Introdução

Em qualquer ramo de atuação profissional, percebe-se um crescimento acentuado na demanda por predições e detecção de tendências junto a variáveis de interesse. Ferramentas computacionais capazes de fornecer predições automáticas acerca de valores futuros de certas variáveis que estão sendo monitoradas já fazem parte do dia-a-dia de muitas empresas privadas e órgãos governamentais, e têm contribuído para o sucesso na definição de políticas estratégicas, em processos de tomada de decisão e em todo tipo de planejamento de curto e médio prazo.

Uma série temporal é dada pelos valores ao longo do tempo de uma variável de interesse, como em:

- ✓ atividades vitais ou funções orgânicas;
- ✓ índices econômicos;
- ✓ índices sociais;
- ✓ variáveis climáticas;
- ✓ variáveis de ecossistemas;
- ✓ monitoramento de operação de sistemas automáticos;
- ✓ monitoramento de processos químicos e físicos.

Sendo a predição uma estimativa de valores futuros a partir do conhecimento do histórico de uma variável até o presente, surgem algumas questões:

- ✓ o histórico de uma variável até o presente é capaz de auxiliar na predição do comportamento futuro?
- ✓ como geralmente a variável de interesse tem seu comportamento atrelado a uma grande quantidade de fatores e a uma complexa rede de interrelações, como é

possível prever seu comportamento sem modelar os fenômenos complexos que regem o comportamento da variável e sem monitorar outras variáveis que influenciam nesse comportamento? Exemplo: como prever a vazão de um rio com base apenas em seu histórico, sem levar em conta a vazão dos afluentes, o nível de chuvas na cabeceira do rio e o seu grau de assoreamento, dentre outros fatores?

2 Metodologia

As primeiras tentativas no campo da predição de séries temporais foram efetuadas nos anos 20, quando YULE (1927) aplicou um modelo autorregressivo linear no estudo de manchas solares. Nos anos 50, DOOB (1953) prosseguiu a investigação com a análise teórica de séries temporais estacionárias. Já nos anos 70, foram propostas as técnicas e metodologias que obtiveram maior destaque a partir de então, reunidas no trabalho de BOX & JENKINS (1976).


Os métodos de Box & Jenkins baseiam-se na proposição de que o valor atual da série temporal é a combinação de p valores precedentes e q impactos aleatórios anteriores, mais o impacto atual. Os p valores antecedentes formam o *componente autorregressivo* e os q impactos prévios formam o *componente de média móvel* da série. A modelagem de uma série temporal objetiva, então, a determinação dos valores de p e q , seguida da estimação dos respectivos coeficientes da combinação linear.

Nos últimos anos, considerável atenção tem sido dedicada a métodos alternativos para o estudo de séries com padrões não-lineares, destacando-se a utilização de redes neurais artificiais. O emprego das arquiteturas MLP e RBF trouxe resultados muito positivos no campo da predição de valores futuros em séries temporais, em virtude do caráter essencialmente não-linear dessas estruturas.

Para o emprego de uma rede neural artificial como preditor de um passo à frente, é necessário definir quais valores passados da série serão utilizados na definição da entrada da rede neural. Feito isso, o problema de síntese do preditor se transforma em um problema de treinamento supervisionado, onde o que se deseja é obter um mapeamento

multidimensional não-linear de entrada-saída, como indicado na seqüência de passos abaixo.

Passo 1: Obter a série temporal, ou seja, os valores históricos da variável a ser predita um passo à frente. Se necessário, normalize os dados (média zero e variância unitária), evitando que o intervalo de excursão dos valores seja qualquer.



Passo 2: Definir quais valores passados da série serão considerados na predição. Suponha aqui que L valores passados consecutivos sejam considerados. Com isso, monte a tabela a seguir, a qual retrata o comportamento desejado do preditor.

s_{t-1}	s_{t-2}	...	s_{t-L}	s_{L+1}
s_1	s_2	...	s_L	s_{L+1}
s_2	s_3	...	s_{L+1}	s_{L+2}
\vdots	\vdots	\vdots	\vdots	\vdots
s_{N-L}	s_{N-L-1}	...	s_{N-1}	s_N
\Downarrow	\Downarrow		\Downarrow	\Downarrow
X_1	X_2		X_L	Y

Passo 3: Separe os dados da tabela acima em 3 conjuntos: conjunto de treinamento, conjunto de validação e conjunto de teste.

Passo 4: Treine a rede neural com o conjunto de treinamento (ela vai produzir um mapeamento do \mathbb{R}^L no \mathbb{R}^1) e pare o treinamento quando for atingido o valor mínimo do erro quadrático médio para os dados de validação. Isso vale no caso de ajuste de pesos iterativo, como ocorre para a rede neural MLP. No caso da rede neural RBF, como o ajuste dos pesos da saída ocorre em um único passo, pode-se empregar os dados de validação para definir o número máximo de neurônios com função de ativação de base radial.

Passo 5: Avalie o preditor recém-obtido junto aos dados de teste.

3 Atividade a ser desenvolvida

3.1 Síntese de um preditor linear

Supondo um modelo de predição linear na forma:

$$x(k) = b_1 x(k-1) + b_2 x(k-2) + \dots + b_L x(k-L) + b_{L+1}$$

monte a matriz $A = \begin{bmatrix} X_1 & \dots & X_L & \bar{1} \end{bmatrix}$, onde $\bar{1}$ é um vetor-coluna de 1's e resolva o seguinte sistema linear:

$$A\vec{b} = Y$$

onde $\vec{b} = [b_1 \ b_2 \ \dots \ b_L \ b_{L+1}]^T$, na forma:


$$\vec{b} = (A^T A)^{-1} A^T Y.$$

3.2 Síntese de uma rede neural MLP

Treine uma rede neural MLP, usando os conjuntos de treinamento e validação. Defina o número n de neurônios na camada intermediária (sugestão: escolha um valor entre 5 e 10)

e adote a função de ativação $g(u) = \tanh(u)$. Repare que $\frac{dg}{du} = 1 - u^2$.

A rede neural é apresentada na figura a seguir, sendo que $m = L$ (número de entradas) e $r = 1$ (número de saídas).



3.3 Síntese de uma rede neural RBF

Sintetizar o mapeamento conforme apresentado em aula. Distribuir gaussianas uniformemente no espaço de entradas e definir um valor adequado para as aberturas (a mesma para todas as gaussianas).


4 Séries temporais a serem tratadas

4.1 Somente para a rede neural MLP

Série 1 (12 atrasos)

O arquivo anexo **serie1.mat** contém as seguintes variáveis: Xtr, Xva, Ytr, Yva

Execute o comando `(load serie1.mat)` no MATLAB.




A série completa

Série 2 (12 atrasos)

O arquivo anexo **serie2.mat** contém as seguintes variáveis: Xtr, Xva, Ytr, Yva

Execute o comando `(load serie2.mat)` no MATLAB.




A série completa

4.2 Para preditor linear, rede neural MLP e rede neural RBF

Série 3 (2 atrasos)

O arquivo anexo **serie3.mat** contém as seguintes variáveis: Xtr, Xva, Ytr, Yva

Execute o comando `(load serie3.mat)` no MATLAB.




A série completa

Série 4 (2 atrasos)

O arquivo anexo **serie4.mat** contém as seguintes variáveis: Xtr, Xva, Ytr, Yva

Execute o comando `(load serie4.mat)` no MATLAB.



A série completa

5 Forma de avaliação

Além de ser considerado o relatório técnico descrevendo e documentando as atividades desenvolvidas, os preditores sintetizados pelo grupo de alunos serão testados junto aos dados de teste, os quais estão de posse do professor.

6 Referências

Box, G. E. P. & Jenkins, G. M. (1976). *Time Series Analysis, Forecasting and Control*. Holden Day, San Francisco.

Bradley, E. (1998). *Time-Series Analysis*. University of Colorado.

Chakraborty, K., Mehrotra, K., Mohan, C. K. & Ranka, S. (1992). Forecasting the Behavior of Multivariate Time Series Using Neural Networks. *Neural Networks*, vol. 5.

Doob, J. (1953). *Stochastic Processes*. Wiley, New York.

Haykin, S. (1999). *Neural Networks – A Comprehensive Foundation*. IEEE Press, New York, 2.^a ed.

Weigend, A. S. e Gershenfeld, N. A. (1993). *Time Series Prediction: Forecasting the Future and Understanding the Past*. Perseus Press.

Yule G. (1927). On a method of investigating periodicities in disturbed series with special reference to Wolfer's sunspot numbers. *Philos. Trans. R. Soci.*, A226.

7 Pesquisadores de apoio

Além do professor da disciplina, os grupos de alunos da disciplina podem solicitar apoio técnico e tirar dúvidas com os seguintes pesquisadores doutorandos da FEEC/Unicamp:

Wilfredo J. Puma-Villanueva (wilfredo@dca.fee.unicamp.br)

Pablo A. D. de Castro (pablo@dca.fee.unicamp.br)

Guilherme P. Coelho (guilherme.coelho@gmail.com)